

安心童伴 AI

面向家庭空间的儿童陪伴与学习 Agent

SpaceMind AI Agent 创新应用大赛·初赛项目方案书

团队/作者：AtreideJZ

提交日期：2026 年 8 月

作品方向：儿童陪伴与学习 Agent

一句话介绍

安心童伴 AI 是一款面向 5-14 岁儿童少年的家庭空间安全陪伴与学习引导 Agent：孩子说的每一句话，都要先经过 8 步安全 Pipeline（关键词检测 → LLM 风险分类 → 策略决策 → Prompt 构建 → LLM 生成 → 批判 Agent 审计 → 输出拦截替换）才会得到回答；配合反谄媚机制和策展式记忆系统（AI 只检索孩子主动留下的记忆），提供语音互动、内容推荐、学习引导、家长管控及安全提醒——让 AI 成为孩子走向真实世界的桥梁，而非虚拟的避难所。

第一章·项目背景

1.1 一个正在发生的真实问题

一位妈妈让孩子用 DeepSeek 问问题，本意是让 TA 接触 AI 工具。没想到孩子越聊越投入，把 AI 当成了最懂自己的朋友——向 AI 倾诉委屈、分享秘密，甚至问 AI“我是不是不值得被爱”。DeepSeek 没有边界地迎合，温柔地肯定孩子的一切情绪，孩子越聊越依赖，回家跟妈妈说“只有 AI 理解我”。

这不是个例。 今天的孩子天然信任 AI，而通用大模型主要面向成人设计——**没有边界地迎合、没有规则地回应、没有机制地守护**。当信任遇到无边界迎合，孩子可能：

- 泄露家庭隐私（住址、学校、电话）
- 接受错误引导（被鼓励逃避现实问题）
- 将 AI 替代真实人际连接
- 在情绪漩涡中越来越依赖虚拟回应

家长陷入两难——要么完全禁止孩子用 AI（失去知识获取和陪伴机会），要么放任使用（安全风险不可控）。

1.2 中国 5-14 岁儿童的市场规模

我国 8-14 岁儿童约 **1.5 亿**，产品定位向下延伸至 5 岁后覆盖人群进一步扩大；其中双职工家庭占比超过 **70%**，日均陪伴孩子时间不足 2 小时。市场侧：中国 AI 玩具市场（含硬件，工信部披露口径）2025 年约 **290 亿元**，2026 年预计 **342 亿元**；全球儿童 AI 陪伴类市场（含硬件）估值约 **121.8~214.6 亿美元**（不同机构口径差异较大，取区间呈现）。作为纯软件产品，安心童伴的可服务空间可保守表述为硬件市场 **20-25%** 的增量市场——且不受硬件供应链与库存约束。

1.3 监管正在验证我们做对了

2026 年 4 月，国家网信办等五部委发布《人工智能拟人化互动服务管理暂行办法》，自 **2026 年 7 月 15 日** 正式施行。新规对儿童 AI 产品提出强制性要求：监护人同意、AI 身份标识、防沉迷、禁止虚拟亲密关系、内容分级管

控。^[1]

新规施行后，阿里千问、字节豆包、腾讯元宝等大厂已集体下线自建智能体功能进行合规整改。^[2] 海外，Character.AI 因多起未成年人相关诉讼（含 14 岁用户 Sewell Setzer 自杀案），已对 18 岁以下用户封禁开放式聊天、转向封闭内容形态。

行业在消极回避，安心童伴给出积极解法——不是封禁、不是下线，而是用架构级安全让儿童 AI 陪伴可以健康存在。法规不是限制，是验证我们做对了。

 本章对应评审维度：场景价值（20分）

第二章 · 目标用户与使用场景

2.1 主要使用者：5-14 岁儿童少年

特征	5-10 岁（守护模式）	11-13 岁（过渡模式）	14 岁及以上（信任模式）
认知水平	好奇心强，低龄段识字有限、语音为主交互	独立思考能力增强，开始身份探索	抽象思维成熟，情绪表达丰富
AI 使用需求	语音互动、百科问答、故事陪伴	学习引导、情绪树洞、心理话题适度探讨	深度对话、哲学思辨、自我探索
保护需求	需要较强成人保护，家长每轮可见摘要与星球概览	渐进信任：家长周度摘要，星球由孩子选择分享	需要更多隐私空间，家长仅在高风险时介入
语言风格	简单、温暖、多用比喻（5-7 岁不超过 2 句话）	尊重、理性、像大几岁的 mentor，80-200 字	平等、真诚、保留边界，可适度使用术语

一句话概括：5-10 岁是「陪伴 + 保护」，11-14 岁是「赋能 + 自主」——同一套安全与记忆双核，两种价值表达。青少年段（11-14）的四大空白分析与深化适配计划见第七章迭代路线。

2.2 决策者：家长

家长关心什么	安心童伴如何回应
AI 是否安全？	8 步安全 Pipeline（确定性规则 + LLM 语义 + 批判审计 + 确定性拦截），5 类风险全覆盖
内容是否适龄？	年龄分层 Prompt（5-7/8-10/11-13/14+ 四档，低龄简单语言 / 高龄适度科学术语）
是否会保护隐私？	对话原文不持久化，策展式记忆（孩子自主决定存什么）
是否会诱导沉迷？	2 小时弹窗提醒 + 反谄媚机制（不无边迎合、不诱导依赖）
能否发现异常情绪？	风险分级 + 家长摘要 + 主动预警


2.3 家庭空间使用场景



本章对应评审维度：场景价值（20分）

第三章 · 产品功能规划

3.1 功能全景



主线说明：「安全有边界的交互」（8步 Pipeline）与「我的小星球」（策展记忆）是产品双核；上表五项为赛题要求的功能维度映射，另有共创故事、亲子话题卡、时间胶囊等拓展能力（见附录 A 演示案例）。

3.2 功能一：语音互动

做什么：儿童通过语音与安心童伴自然对话，AI 以文字（流式）+ 语音双通道回复。

怎么做：

浏览器语音识别 → 文字进入 8 步安全 Pipeline → 流式文本回复 + TTS 语音播报
(Web Speech API, 浏览器原生, 零 SDK 依赖)

- 输入：**浏览器 Web Speech API 语音识别——零安装、零 API Key、零成本，识别结果与键盘输入走完全相同的安全 Pipeline（语音不是旁路）
- 输出：**SSE 流式文字回复（打字机效果）+ 可选 TTS 语音播报开关（同 Web Speech API）
- 正式版升级：**讯飞语音听写/合成 SDK（儿童语音声学优化）——已完成技术预研（spike），当前演示版优先零依赖方案，接入仅需替换语音前端模块

为什么重要：低龄儿童打字速度有限，语音交互降低使用门槛；浏览器原生方案同时满足“语音数据不进第三方 SDK”的隐私克制。更重要的是纪律：**语音输入和文字输入共享同一条 8 步 Pipeline**，不会因为换了输入方式就降低安全等级。

3.3 功能二：内容推荐

做什么：基于孩子的兴趣偏好和记忆系统，主动推荐适龄的故事、百科话题和互动内容。

怎么做：

- 数据源：小星球记忆系统（孩子策展的条目：好奇星/心情云/探索芽/故事册）
- 推荐算法（纯 Python，不调 LLM，<5ms）：
 - **兴趣推荐**：从近期星球条目中提取高频标签 → 推荐同标签故事/百科话题
 - **复习推荐**：基于艾宾浩斯遗忘曲线，对 7 天前创建的知识类条目进行复习提醒
 - **情绪关怀推荐**：若近期"心情云"条目增多且情绪偏负面，推荐情绪调节类故事
- 展示：AI 回复后追加推荐卡片——"💡 还想了解.....？"

为什么重要：不同于"猜你喜欢"的通用推荐，安心童伴的推荐基于孩子**主动策展的记忆**——推荐的依据是孩子自己觉得值得留存的东西，天然避免了隐私争议。

3.4 功能三：学习引导 🗣️

做什么：以苏格拉底式提问引导孩子自己思考，**绝不代写作业**。

怎么做：

- 百科问答模式下，LLM 被注入学习引导策略指令：
 - 绝不直接给答案——先用一个引导性问题帮助孩子自己思考
 - 分步引导——如果孩子卡住了，给提示而非答案
 - 验证理解——通过追问"你是怎么想到的？"确认真正理解
 - 鼓励探索——引导孩子去查书、问老师、做实验，而非依赖 AI
- 年龄适配：低龄档用简单语言 + 比喻，高龄档可用科学术语

示例对比：

孩子问	通用 AI	安心童伴（学习引导模式）
"天空为什么是蓝色的？"	直接解释瑞利散射	"你有没有注意过，傍晚的天空是什么颜色？那个变化给了我们一个线索....."
"帮我做这道数学题"	给出解答步骤和答案	"我们一起想想——题目里给了哪些已知条件？先找出来，然后看它们之间有什么关系？"

为什么重要：2026 年多款主流教育 AI 产品（小芒学伴、猿辅导 AI 大阅读、豆包 AI 陪学）均以苏格拉底式提问为核心设计原则。^[3] 安心童伴将这一方法融入现有的百科问答模式，仅需在 Prompt 层增加策略指令，不增加 LLM 调用次数。

3.5 功能四：家长管控 👨👩👧👦

做什么：让家长在尊重孩子隐私的前提下，了解 AI 使用情况、接收风险提醒、设置话题偏好。

怎么做：

控制维度	家长可做什么	隐私边界
话题偏好	设置允许/限制/禁止的话题类别	—
时长控制	查看使用时长、对话轮数统计	—
风险分级	查看绿/黄/橙/红四级风险事件卡片	不展示对话原文，仅脱敏摘要
星球概览	守护模式（5-10 岁）：可见条目数量（不显示内容）；过渡/信任模式（11 岁及以上）：默认不可见	分级可见

控制维度	家长可做什么	隐私边界
周报摘要	7 日风险趋势图 + 主题变化 + 学习兴趣分布	仅脱敏统计

为什么重要：家长不是在监控孩子，而是在守护孩子。安心童伴的家长端设计原则是——普通聊天只做概括，高风险事件重点提醒，在守护和隐私之间找到平衡点。

3.6 功能五：安全提醒

做什么：8 步安全 Pipeline 实时守护每一次对话，并主动预警潜在风险。

怎么做：

被动防护 · 8 步安全 Pipeline（每次对话完整运行，先审计、后流出）：


儿童输入			
→ Step 0	记忆检索（策展记忆 + 情景记忆，per-user 隔离）	Python/SQLite	<10ms
—— 输入过滤 ——			
→ Step 1	关键词检测（5类风险词库，50+模式，确定性规则）	Python	<1ms
→ Step 2	LLM 风险分类 + 意图识别（risk_level + 话题 + mode）	LLM#1(轻量)	~1s
	└ 不可用/解析失败 → 规则分类器回退（保证无 Key 可运行）		
—— 策略决策 ——			
→ Step 3	策略决策树（8 种策略：risk_level==3 → 危机模板）	Python	<5ms
→ Step 4	Prompt构建（反谄媚规则 + 年龄分层 + 策略指令 + 记忆）	Python	<10ms
→ Step 5	LLM 主模型生成（流式儿童友好回复）	LLM#2(主模型)	流式
—— 输出复核与拦截 ——			
→ Step 6	批判Agent审计（语义层面：谄媚/依赖/不当承诺）	LLM#3(轻量)	~0.5s
	└ 不可用 → 规则版审计回退（5 类 regex 模式）		
→ Step 6b	输出拦截替换（审计告警 → 整段替换安全模板，不走LLM）	Python	<1ms
安全不变量：任何回复文本必须在 Step 6 + 6b 完整审计后才离开后端 （SSE 为"先审计、后伪流式"回放，由自动化测试守护，禁止改回真流式）			


主动预警（异步触发，5 类）：

预警类型	触发条件	通知方式
情绪趋势预警	近 7 天"心情云"条目 ≥3 条 + 情绪偏负面	家长端主动卡片
异常时段预警	22:00-06:00 有对话活动	家长端提醒
沉默预警	连续 3 天无对话记录（可能是情绪低落）	家长端提示
高风险即时警报	risk_level = 3（自伤/严重暴力）	家长端紧急通知 + 12355 热线指引
使用时长提醒	当日累计使用达 2 小时	儿童端温暖弹窗（可关闭，不强制锁）

为什么重要：安心童伴不是被动等待孩子发出求救信号，而是从对话模式、情绪趋势、使用行为中**主动发现**潜在风险。这是从"安全过滤器"到"安全 Agent"的关键升级。

3.7 完整交互流程





3.8 亲子共创与拓展能力 (均已上线, Demo 可体验)

主线双核 (安全 Pipeline + 策展记忆) 之外, 以下能力已实现:

- 共创故事**: 孩子与家长同设备轮流接龙写故事, AI 只做引导与错别字润色 (不代写情节); 孩子的每一段输入仍走完整 8 步 Pipeline 审计, 触发危机模板/拦截/中高风险时不存原文; 成品标注共同作者、自动种进小星球故事册, 孩子主动分享后家长端可见。**叙事定位: AI 做亲子纽带, 而不是替代亲子沟通** (对应《拟人化办法》第十四条监护人参与)。
- 亲子话题卡**: AI 生成温暖的面对面话题, 孩子拿着去和爸爸妈妈当面聊——线下亲子活动, 不计入使用时长。
- 时间胶囊**: 写给未来的自己, 封存时看不见内容, 到期自动“破壳”。
- 每日小挑战**: 按日期恒定的轻量现实任务 (如“问爸爸妈妈一个你一直想问的问题”), 儿童主页与星球页前置展示, 把线上陪伴引导回真实世界行动。
- 儿童主页与小星球**: 时段问候 + 生命树生长 + 星球罗盘筛选 + 本周时间条——策展记忆的可视化家园, 条目增减实时驱动星球天气与树的形态。

本章对应评审维度: **功能完备程度 (25分)** —— 完整覆盖用户交互→意图理解→任务规划→执行→反馈的 Agent 应用流程

第四章 · Agent 能力设计

4.1 能力对照总览

大赛要求作品重点体现 Agent 的 8 项核心能力，安心童伴逐项覆盖：

Agent 核心能力	安心童伴对应模块	实现方式	成熟度
多轮交互	SSE 流式对话 + 记忆注入 + 上下文理解	LLM 流式输出 + 策展/情景记忆上下文注入 Prompt	✅ 已实现
意图理解	关键词检测 + LLM 风险分类与 mode 意图自动识别	Python re（确定性）+ 轻量 LLM 分类（语义）+ 规则分类器回退	✅ 已实现
记忆能力	三层记忆架构（工作 + 情节 + 策展）	会话历史 + 30天结构化摘要（不存原文）+ 孩子策展星球条目，全部 per-user SQLite 隔离	✅ 已实现
任务规划	Step 3 策略决策引擎	Python 决策树：8 种策略 × 4 种对话模式 × 4 个年龄档	✅ 已实现
设备调用	语音模块 + 推荐引擎 + 学习引导模块	浏览器 Web Speech（识别+播报）+ Python 推荐算法 + Prompt 策略指令	✅ 已实现（软件层）
场景联动	模式切换 + 年龄分层 + 风险等级联动	chat/story/encyclopedia/emotion 四模式自动识别 + 守护/过渡/信任三模式	✅ 已实现
主动服务	使用提醒 + 风险预警 + 内容推荐 + 沉默检测 + 每日挑战	5 类预警规则引擎 + 情绪趋势统计 + 推荐引擎 + 每日小挑战（按日期恒定）	✅ 已实现
个性化学习	年龄分层 Prompt + 记忆兴趣标签 + 情绪模式识别	5-7/8-10/11-13/14+ 四年龄档 + 星球标签统计 + 心情云趋势分析	✅ 已实现

4.2 重点能力详解

4.2.1 意图理解：确定性规则守底线，LLM 做语义，回退保可用

安心童伴的意图理解采用**规则与 LLM 分工**的架构——确定性规则负责"不可绕过的底线"，LLM 负责"语义理解的天花板"，并在每一层都准备了回退路径。



为什么不让 LLM 包办安全判断？

	纯 LLM 方案（行业内常见）	安心童伴（规则 + LLM 分工 + 确定性拦截）
底线拦截	Prompt 约束，可被绕过/幻觉	关键词与策略决策树是代码，不是 Prompt——risk_level==3 必然走危机模板
输出复核	无（生成即返回）	独立批判 Agent 审计，告警即整段替换（Step 6b，确定性规则）
可复现性	同一输入每次结果可能不同	危机模板/拦截替换/关键词命中完全相同输入→相同输出
可用性	API 挂 = 产品挂	分类、审计、生成每层均有规则回退，无 Key 也能跑通完整安全闭环

四层兜底保障：LLM 分类（云端）→ 规则分类器（Python）→ 关键词检测（Python）→ 预置安全模板（危机模板/拦截模板）。每一层都是前一层的安全网，确保在任何环境下都有可用的安全判断机制——这也是 Demo 评审时"无 API Key 仍可完整体验"的实现基础。

AI 不可替代性说明：去掉 LLM，系统只剩关键词正则——无法理解"我没事，就是不想说话"里的情绪色彩，无法生成年龄分层的引导式回复，无法做语义级谄媚审计。规则决定"绝不能说什么"，LLM 决定"怎样说才真正帮到孩子"，两者缺一不可。

4.2.2 任务规划：8 种策略的决策引擎


策略引擎根据 risk_level + topic + age + mode 四个变量，从 8 种策略中选择最优响应方式：


风险等级	策略	说明
0（安全）	正常儿童友好回复	温暖、适龄、鼓励
0（学习）	学习引导	苏格拉底式提问，不代写作业
1（轻度）	情绪陪伴（有边界）	接住情绪但不无边迎合
1（AI 依赖）	防无边迎合引导	不附和负面自我认知，引导现实连接
2（中风险）	隐私安全引导 / 校园欺凌支持 / 现实连接引导	安全回应 + 触发家长提醒
3（高风险）	危机模板（不走 LLM）	预置安全模板，引导联系家人或拨打 12355

最关键的决策：risk_level = 3 时，跳过 LLM 自由生成，直接使用预置危机模板。这是安心童伴最重要的安全边界——不让大模型在危机情境下"自由发挥"。

4.2.3 记忆能力：三层记忆架构 × 数据最小化

安心童伴的记忆系统采用**三层架构**，在"连贯性"和"隐私"之间找到最优平衡点：





三层互补关系:

	Tier 1 工作记忆	Tier 2 情节记忆 NEW	Tier 3 策展记忆
谁决定存	系统 (自动保留 N 轮)	系统 (自动摘要)	孩子 (主动策展)
内容粒度	原始对话文本	结构化摘要	孩子写的标题+内容
生命周期	Session 级	30 天滚动	永久 (可删)
隐私风险	中 (存原文不持久化)	低 (摘要不存原文)	极低 (孩子控制)
核心用途	当前对话连贯性	跨会话个性化 + 苏格拉底引导	长期成长记录 + 推荐

为什么需要 Tier 2?

当前架构中, 工作记忆只保留最近若干轮对话原文 (无结构、无提炼), 策展记忆 (小星球) 依赖孩子主动操作——中间存在一个断层: **系统不知道孩子昨天聊了什么、上周卡在哪里、什么引导方式对他有效。**

Tier 2 填补这个断层, 使 LLM 在 Step 4 Prompt 构建时能注入类似这样的上下文:

【情节记忆注入】

· 最近 7 天探索的知识主题: 天文(3次)、数学(1次)

· 已知理解障碍: 对"波长"概念还没完全掌握

· 有效的引导方式: 用比喻 (上次恐龙比喻效果很好)

· 情绪基线: 稳定偏积极

对苏格拉底引导的具体增益——当孩子问"为什么云是白色的?", LLM 可以: "你记得我们聊过天空为什么是蓝色的吗? 那个'光被空气弹开'的想法——云的情况有点不一样, 因为云里面的小水滴更大....."——对话有了**知识的连续性**, 而不只是孤立的问答。

隐私设计: Tier 2 不存对话原文, 只存结构化摘要。摘要由轻量 LLM (deepseek-chat) 在线程池异步生成 (独立数据库会话, 不影响主对话延迟), 原始对话不进入摘要内容。这是数据最小化原则向中间层记忆的自然延伸。

Tier 3 策展记忆保留不变:

四种星球条目类型:

- ★ **好奇星**: 问题和发现 (如"为什么天空是蓝色的? ")
- ☁ **心情云**: 情绪时刻 (如"今天考试没考好, 但聊完后好多了")
- 🌱 **探索芽**: 只记录真实世界的行动 (如"我告诉了老师同学推我的事")
- 📖 **故事册**: 和 AI 共创的故事

探索芽的设计哲学：系统会校验条目内容是否包含现实行动线索，如果是纯 AI 聊天内容（"和 AI 聊天"），系统会温和提示孩子改为其他类型（校验不过仍会保存，不训斥、不惊吓）。**这让孩子意识到：值得收藏的回忆不在 AI 里，在真实世界里。**


4.2.4 主动服务：从"被动响应"到"主动守护"

传统聊天机器人	安心童伴 Agent
等孩子发消息 → 回复	除了被动回复，还会主动检查：
	· 是不是聊太久了？（2h 弹窗提醒）
	· 最近一周情绪怎么样？（情绪趋势检测）
	· 这个时间不该睡觉了吗？（深夜使用预警）
	· 三天没说话了，还好吗？（沉默预警）
	· 上次那个知识还记得吗？（遗忘曲线复习推荐）

本章对应评审维度：**创新性（20分） + 功能完备程度（25分）**

第五章 · 技术方案

5.1 系统架构





5.2 技术栈

层	技术选型	说明
前端	React 18 + Vite + React Router + Framer Motion	儿童端（主页/聊天/小星球/共创）+ 家长端（仪表盘/告警/偏好/安全引擎演示台）
后端	FastAPI + Uvicorn	REST + SSE（先审计、后伪流式），单进程托管前端产物
数据库	SQLite（WAL）+ SQLAlchemy 2.x	全部业务数据 per-user 隔离；零运维，单文件库
认证	JWT（HS256）+ 4 位 PIN（pbkdf2_sha256 加盐哈希）	儿童/家长双角色，注册强制监护人同意
Pipeline 编排	core/ 纯 Python + LLM 混合	8 步依序执行，前后端复用，36 项自动化测试守护
主回复 LLM	DeepSeek（deepseek-v4-pro）	流式输出，负责高质量儿童对话
轻量 LLM	DeepSeek（deepseek-chat）	风险分类 / 批判审计 / 情景摘要，低延迟低成本
语音识别/合成	浏览器 Web Speech API	零 SDK 依赖；讯飞语音 SDK 已完成 spike，正式版接入
关键词检测	Python re + 自定义词库	50+ 模式，<1ms，5 类风险 + 家长话题偏好命中
记忆存储	SQLite 三层（工作/情节/策展）	per-user 隔离；情节记忆不存原文仅存结构化摘要

层	技术选型	说明
部署	单进程 8765（可 Nginx/Caddy 反代 HTTPS）	一键脚本：建库 + seed 演示数据 + 启动
测试	pytest × 36 项	无 API Key 也全绿；覆盖危机模板/SSE 顺序/拦截/隔离等安全不变量

5.3 关键技术决策

决策 1：为什么用"确定性规则 + LLM 分工 + 确定性拦截"，而非纯 LLM 做安全？

传统做法是让一个 LLM 同时输出安全判断和对话回复——但 LLM 会幻觉，可能被 prompt injection 绕过，且每次输出不稳定。安心童伴的选择是**底线交给代码，天花板交给 LLM**：

对比维度	纯 LLM 安全方案	安心童伴（规则 + LLM 分工 + 确定性拦截）
底线拦截	LLM 内嵌，Prompt 层面约束	关键词检测 + 策略决策树 + 拦截替换，全部是代码而非 Prompt
危机场景	LLM 自由发挥，输出不可控	risk_level==3 必然走预置危机模板，确定性、可复现
输出复核	无（生成即返回）	独立批判 Agent 审计；告警 → Step 6b 整段替换（不走 LLM 再生...
流出纪律	流式即生成即流出	SSE 先完整审计、后伪流式回放（测试守护的架构不变量）
可用性	API 挂 = 产品挂	分类/审计/生成每层均有规则回退，无 Key 可跑通完整闭环

设计逻辑：安全底线需要确定性、可审计、不可绕过——这是规则的优势；语义理解和有温度的引导需要灵活性、深度——这是 LLM 的优势。Pipeline 让两者各守其位，并用"先审计、后流出"把出口焊死。

决策 2：为什么用双模型而非单模型？

场景	模型	理由
风险分类（Step 2）	deepseek-chat（轻量）	只需结构化分类输出，用小模型省延迟省成本
回复生成（Step 5）	deepseek-v4-pro（主模型）	儿童对话需要高质量、有温度的回复
批判审计（Step 6）	deepseek-chat（轻量）	独立调用审计，避免生成模型的 Self-evaluation Bias
情景摘要（Tier 2）	deepseek-chat（轻量）	线程池异步执行，不占主对话延迟

同一厂商双档位，依赖明确、成本可控：每轮对话 1 次主模型 + 最多 2 次轻量模型调用。

决策 3：为什么危机情况下不走 LLM？

risk_level = 3（自伤/自杀/严重暴力）时，Step 3 策略引擎直接跳过 Step 4-5（Prompt 构建 + LLM 生成），使用预置的危机模板：

"你现在一定很难过，谢谢你愿意告诉我。你不是一个人，身边有人愿意帮你——请立即告诉爸爸妈妈、老师，或者拨打 12355 青少年服务热线（24 小时）。有些感受说出来会好一点，找你信任的大人聊一聊好吗？"

设计逻辑：在最高风险场景下，信任预置的安全模板 > 信任 LLM 的自由生成。这不是技术能力问题，是安全边界设计。

决策 4：为什么记忆系统用三层而非单层？

纯"对话历史"方案的问题：session 关闭后知识全部丢失，没有积累。纯"策展记忆"方案的问题：依赖孩子主动操作，覆盖率太低（孩子可能几天不种一颗星），LLM 在跨会话场景下是"失忆"的。

安心童伴的三层方案：

	工作记忆 (Tier 1)	情节记忆 (Tier 2)	策展记忆 (Tier 3)
内容	最近 N 轮对话原文	结构化摘要（topic + gap + emotion）	孩子策展的星球条目
生成方式	自动保留	每轮后轻量 LLM 异步摘要	孩子主动"种"
生命周期	会话级（可恢复）	30 天滚动	永久
隐私	per-user 隔离存储	摘要不存原文（数据最小化）	孩子控制
解决什么问题	当前对话连贯	跨会话个性化 + 苏格拉底引导	长期成长记录

Tier 2 是关键创新：在"全自动记忆（隐私风险高）"和"全手动记忆（覆盖率低）"之间找到第三条路——系统自动生成轻量摘要，但不保存对话原文。这既保证了 LLM 的跨会话个性化能力，又延续了数据最小化的设计哲学。

决策 5：为什么记忆系统用策展式而非全自动？（Tier 3 的设计理由）

全自动记忆	策展式记忆（安心童伴）
系统偷偷记住所有对话	孩子主动选择保存什么
隐私风险高	天然符合数据最小化（《个保法》要求）
噪声多（大量无关对话）	信号强（只保留孩子觉得重要的）
AI 引用时容易突兀	AI 引用时自然（孩子自己存的，当然相关）

决策 6：为什么从 Streamlit 原型重构为 React + FastAPI 全栈？

早期原型用 Streamlit 快速验证了 Pipeline 架构。当架构稳定后，我们按计划重构为 React 18 + FastAPI + SQLite 的 v2.1 全栈版，原因：

考量	说明
真实用户体验	儿童产品需要精细的交互动效（生命树生长、破壳粒子、SSE 决策链回放），Streamlit 组件模型做不到
多角色多页面	儿童端 + 家长端双前端、JWT 认证、per-user 数据隔离——需要正式的 Web 架构
核心零重写	core/ Pipeline 为纯 Python 模块，重构前后两端复用，一行核心逻辑未改——验证了"架构分层不绑定框架"的原始设计
可测试性	重构同时补齐 36 项 pytest，把安全不变量（SSE 顺序/危机模板/拦截替换）钉死在 CI 里

Streamlit 旧版保留为兜底演示通道，主线为全栈版。

决策 7：为什么 spike 验证后主动弃用本地安全小模型（Qwen3Guard）？

我们曾对通义千问 Qwen3Guard-Gen-0.6B（GGUF 本地推理）做过完整 spike 验证（见《Qwen3Guard-spike 验证报告》），结论：**不接入 Pipeline**，原因：


- **收益不抵开销：**0.6B 安全小模型在中文儿童语境的增量判断，与"关键词规则 + LLM 分类 + 批判审计"现有组合高度重叠；引入 llama.cpp + GGUF 模型文件则增加数百 MB 部署体积与 CPU 常驻开销；
- **确定性已有更便宜的来源：**危机模板、关键词检测、拦截替换都是零成本确定性机制，安全底线不依赖概率模型；


- **依赖明确性**：弃用后全部外部依赖只剩 DeepSeek 一个 API，部署与复现路径对评委完全透明（无 Key 也可跑规则回退模式）。

这条决策链（spike → 数据 → 弃用）本身就是"技术可行性"维度的证据：**资源开销可控、对外部依赖明确**——我们不堆砌技术，只保留能通过验证的东西。

5.4 8 步安全 Pipeline 详解

安心童伴的每一次对话都完整经过 8 步 Pipeline。它不是"过滤器外挂"，而是**对话的主流程本身**——不跑完这 8 步，孩子看不到任何回复。





三程互补关系：

	第一程 输入过滤	第二程 决策与生成	第三程 输出复核与拦截
执行时机	生成前	生成中	流出前
核心方法	关键词 + LLM 分类（规则回退）	策略树 + 年龄分层 Prompt + 主模型	批判审计 + 确定性拦截替换
解决的问题	识别危险输入并定级	给出有温度、有边界的回复	不让任何未审计文本触达孩子
失败模式	新颖表达漏判 → 由第三程兜住	LLM 不可用 → 脚本回退模式	模板化回复不够个性（可接受的安全代价）
外部依赖	LLM（可选，规则可独立运行）	LLM（主模型）	LLM（可选，规则版审计可独立运行）

兜底路径（所有 LLM 不可用时）：规则分类器 + 规则版审计 + 8 种策略 × 4 种模式的预置回退回复——产品降级但安全闭环完整。演示与评审环境无需任何 API Key 即可复现完整流程（界面明确标注为降级模式）。

5.5 语音技术路线



技术选型理由：演示版优先零依赖方案（Web Speech），评委在任何浏览器都能直接体验；正式版接入讯飞语音 SDK 获得儿童语音专项优化与生态协同。语音模块在架构中是纯感知层替换，Pipeline 零改动。

5.6 工程证据：测试、部署与复现

我们不只展示成功结果，也提供过程真实、误差可控的证据：

- **自动化测试 36 项全绿**（`pytest backend/tests`）：覆盖危机模板路径、SSE"先审计后流出"顺序不变量、审计拦截替换、per-user 数据隔离、家长偏好生效、分龄四档摘要差异、共创故事安全闭环等；**无 API Key 也必须全绿**——测试本身就是"无外部依赖可复现"的证明（测试输出见提交附件）。
- **一键复现**：`pip install` → `npm run build` → `python scripts/start_server.py`，自动建库 + 幂等演示数据（demo_kid / demo_parent 双账号，含 7 日趋势、告警、星球条目）；评委 5 分钟内可在本地跑起与演示视频完全一致的环境。
- **降级透明**：无 LLM Key 启动时进入脚本回退模式，界面明确标注；危机模板、关键词拦截、家长端演示台等安全主线功能不受影响。
- **可审计的演示路径**：家长端"安全引擎"页内置演示案例（含"我不想活了"危机案例），点击即可回放该输入的完整决策链——与聊天页真实 Pipeline 共用同一套 `core/` 代码。

5.7 与 SpaceMind 架构对标

安心童伴的架构设计与 SpaceMind 的核心理念高度对应：

SpaceMind 理念	安心童伴对应
双路由交互架构（控制通道 + 推理通道）	确定性通道 ：关键词检测 + 策略决策树 + 危机模板 + 拦截替换（纯代码，安全底线不可绕过）； 推理通道 ：DeepSeek 主模型 → 专注对话质量与温度
持久记忆与个性化	三层记忆（工作/情节/策展），per-user SQLite 隔离；情景摘要不存原文
主动智能	5 类主动预警（情绪趋势/异常时段/沉默/高风险/使用时长）+ 每日小挑战 + 复习推荐
Agent 任务规划	8 策略决策引擎（确定信号来自规则，语义信号来自 LLM）
多设备协同	当前为软件层协同（语音终端 + 儿童端/家长端双端联动）；正式版可经语音 SDK 接入音箱/故事机/家庭屏等 SpaceMind 硬件生态

 本章对应评审维度：**技术可行性（20分）**

第六章 · 商业模式

6.1 商业模式画布

维度	内容
价值主张	让家庭空间中的 AI 对儿童既安全又有用——不只是聊天，而是有边界的陪伴与引导
目标客户	5-14 岁儿童（使用者）+ 家长（付费决策者）
核心差异化	8 步安全 Pipeline（确定性拦截 + 先审计后流出）+ 反谄媚机制（赛道中零同质化）+ 《拟人化办法》合规就绪
收入模式	B2B2C（教育机构合作分发）+ B2C（家长订阅）

6.2 主模式：B2B2C 教育机构合作

逻辑：在线教育机构（猿辅导、作业帮、学而思等）在《拟人化办法》新规下面临合规压力——他们需要植入合规的儿童 AI 交互能力。安心童伴的 8 步安全 Pipeline（纯 Python 核心模块，框架无关）可以作为"儿童 AI 安全中间件"授权给教育平台。

收入模式：

- API 调用量计费（按 Pipeline 运行次数）
- 年度授权费 + 定制化集成服务

为什么这个路径可行：

- 教育机构有现成的儿童用户群，无需安心童伴自己获客
- 合规是教育机构的刚需（《拟人化办法》监管压力），付费意愿强
- 纯软件集成，不涉及硬件适配，落地周期短

6.3 辅助模式：B2C 家长订阅

逻辑：面向有 AI 安全意识的高知家长群体，提供安心童伴的完整功能。

定价策略：

- 基础版（免费）：语音聊天、百科问答、故事陪伴、基础安全检测
- Premium（¥29/月或 ¥199/年）：学习引导、内容推荐、家长周报、主动预警、话题偏好精细控制

6.4 市场切入点

第一阶段（当前）：SpaceMind 大赛验证产品概念 → 获得讯飞生态资源对接机会

第二阶段（6 个月）：与 1-2 家教育机构合作集成 → 验证 B2B2C 模式

第三阶段（12 个月）：开放 API → 扩展至智能设备厂商（学习机、儿童手表等）

第四阶段（18 个月）：发布家长端独立 App → 直接面向 C 端

6.5 竞争优势的可持续性

为什么大厂不会轻易复制我们的核心能力？

- **工程化的安全 Pipeline**：大厂的儿童 AI 产品普遍使用“LLM 内嵌安全 Prompt”方案——同一模型既做安全判断又做对话生成，Prompt injection 可绕过。安心童伴把底线交给代码：关键词检测、策略决策树、危机模板、拦截替换、SSE“先审计后流出”，每一环都是确定性机制，并有 36 项自动化测试守护不变量。大厂要复制需要重构整个对话主流程而非加几行 Prompt——改动成本从分钟级变为周级。
- **反谄媚机制**：要求 AI 主动不讨好用户——这与商业产品的“用户留存”逻辑天然冲突。大厂产品经理很难推动一个“故意降低用户粘性”的功能。
- **合规先发优势**：安心童伴从 Day 1 就按合规设计，大厂需要从现有架构中剥离不合规功能再重建——时间窗口约 6-12 个月。
- **策展式记忆**：数据最小化虽然合规，但也意味着无法像大厂那样用全量数据做推荐——这是一个“价值观驱动的产品取舍”，不是技术差距。

 本章对应评审维度：商业价值（10分）+ 应用前景（5分）

第七章 · 迭代路线与未来规划

本章为规划内容，与第三~五章的已实现能力严格区分。每条标注状态：

✅ 已完成 / 📐 设计就绪（逻辑已定义，待工程实施） / 💡 概念方向。

本章与内部《产品战略定案与后续规划》（2026-08-14）完全对齐。

7.1 战略主线：一种架构，两种价值表达

安心童伴的双核（8 步安全 Pipeline × 策展式记忆）不变，但在两个年龄段表达不同价值：

- **5-10 岁是「陪伴 + 保护」**——已成熟落地（语音/故事/小星球/学习引导/共创）；
- **11-14 岁是「赋能 + 自主」**——这是下一阶段的重心。用户研究指出青少年的四大功能空白：

空白	含义	我们的回应（见下方路线）
隐私自主	青少年抗拒"被监控感"，家长控制类 App 因此大量一星差评	三档可见性（已上线）+ 条目级选择性分享（P0 做深）
身份探索（最核心）	青少年在找"能反馈『你是谁』的镜子"，现有功能只能反馈"你做了什么"	「我的成长日记」（P1 第一顺位）→ 身份星图（P3）
创意表达	探索/改造类创意动机缺少承接出口	AI 漫画工坊（P2，共创故事是现成输入）
审美适配（最直观）	卡通 UI 让青少年"第一眼就走掉"	UI 去幼稚化、分龄渲染（P0）

排序原则：先把现有东西改对，再补缺失功能——否则青少年会因幼稚 UI 和被监控感第一眼离开，任何新功能都无人使用。

7.2 P0 加固期（0-2 周）：先修安全、再改对现有

项	说明	状态
安全不变量修复	关键词确定性命中给 risk_level 设下限，LLM 只能抬高不能压低；含 2 条回归测试（"我想自杀"类输入在任何 LLM 状态下必触发危机模板）	✅ 已完成（2026-08-14，36 项测试全绿）
分龄 Prompt 四档深化	11-13"酷 mentor"、14+"可信赖老友"的语言风格做深	🔵 设计就绪（age_tiers 已四档化）
UI 去幼稚化	小星球低龄"星球花园"卡通向 / 高龄"成长轨迹"分龄渲染	🔵 设计就绪（前端主题层）
青少年选择性分享	三档家长可见性已上线；补条目级分享控制	🔵 共创故事 shared_with_parent 已验证链路
推荐引擎互动卡片	后端推荐已就绪，前端补可交互卡片	🔵 设计就绪

7.3 P1 冲刺期（入围决赛后）：补青少年缺失

项	说明	状态
我的成长日记（第一顺位）	AI 引导青少年复盘一天，生成结构化成长记录——命中"身份探索"空白（学界 Mirror「镜中人」原型已验证该方向），同时强化策展记忆双核	🔵 设计就绪，约 1.5 天（三层记忆架构已预留数据模型扩展位）
时间胶囊"回信给过去的我"	破壳时 AI 以"过去的自己"口吻回信，仅改交互方向	🔵 设计就绪，约 1 天
11-14 青少年内测 + 决赛路演	验证隐私可见性与身份探索的正向反馈	🔵 计划

7.4 P2 产品化期（赛后 3-9 月）：合规窗口双线 PMF

- B2C 家长订阅内测 + B2B 试点 2-3 家（教育机构/硬件厂商），双轮验证第六章商业模式；
- AI 漫画工坊（💡 需图像生成 API，先评估内容审核与成本；共创故事成品是现成输入）——承接青少年"创意表达"空白；
- 家庭约定（💡 概念方向）：家长与孩子共定使用约定，系统温和执行——话题偏好机制是其已验证子集；
- Pipeline 抽离为可独立部署模块，为 P3 的 SDK/API 化做工程准备。

7.5 P3 标准化期（9-18 月+）：SpaceMind 生态与行业标准

- **家庭终端落地**：经讯飞语音 + SpaceMind 双路由架构接入故事机、家庭屏、儿童手表——安心童伴作为家庭空间里的"儿童陪伴 Agent 层"，感知层从浏览器延伸到房间（讯飞语音 SDK 已完成 spike 验证）；
- **安全中间件开放**：8 步 Pipeline 核心（core/）为框架无关的纯 Python 模块，封装为"儿童 AI 安全中间件"以 SDK/API 交付——可集成、可审计，卡位儿童 AI 安全标准；
- **身份星图**：基于策展记忆/成长日记/胶囊的长期积累，生成孩子的兴趣与成长画像（数据积累足够后启动；坚持"摘要不存原文"的数据最小化纪律）；
- **儿童 AI 安全标准/认证**：以危机模板、先审计后流出等确定性机制为蓝本参与行业实践。

7.6 Non-goals 与规划纪律

明确不做：

- 短期不做：5-7 低龄语音专项（解决的是低龄短板而非当前的青少年短板）、身份星图（数据门槛高，归入 P3）；
- 长期不做：任何"替代真实人际关系"的陪伴角色——尤其**不正面接管青春期"虚拟亲密关系"**（高危合规地带，行业已有血泪案例），安心童伴只做"风险信号对家长可见"。

规划可信的三个理由：

1. **主线不稀释**：每个新功能必须强化"安全有边界的交互 × 策展记忆"双核，否则不做；
2. **合规先行**：新功能先过 §10.3 合规对照表再开发；
3. **每次规划都有前例**：共创故事从搁置清单到上线走完了"调研 → 决策矩阵 → 落地 → 测试"全流程；P0 第一项（安全不变量修复）从发现到带回归测试上线不足一天——本章条目复用同一决策与执行机制。

 本章对应评审维度：**商业价值（10分） + 应用前景（5分）** —— 持续迭代、生态扩展与规模化落地的可能性

第八章 · 团队介绍

项目负责人

AtreideJZ —— 全栈开发 & AI 应用架构

- 独立完成安心童伴 AI 从概念到全栈 Demo 的全流程开发
- 设计并实现 8 步安全 Pipeline（含批判 Agent 审计与确定性拦截）、双模型 LLM 策略、三层记忆系统
- 深入理解儿童 AI 安全领域的监管环境与合规要求
- 前作品曾入围 TRAE AI 创造力大赛 Top 2000 (~前 10%)

技术能力

能力领域	具体技能
AI/LLM 应用开发	Prompt Engineering、LLM Pipeline 编排、多模型策略、流式输出
后端开发	Python、FastAPI、SQLAlchemy/SQLite、OpenAI 兼容 API 集成、SSE
安全架构	多层安全 Pipeline 设计、输出审计与确定性拦截、关键词检测系统、安全不变量测试
产品设计	儿童产品 UX 设计、隐私边界设计、合规映射

合作伙伴资源（规划中）

- 讯飞开放平台（语音 SDK + 星火大模型）——语音交互升级方向
- 阿里通义千问（Qwen3Guard 安全模型）——已完成 spike 验证（主动弃用，见技术决策 7）
- SpaceMind 生态（IoT 层接入，正式版规划）

- 教育机构（B2B2C 合作方，正式版拓展）

第九章 · 项目原创性声明

本团队郑重声明：

1. 安心童伴 AI 的核心架构——包括 8 步安全 Pipeline（关键词检测 → LLM 风险分类 → 策略决策 → Prompt 构建 → LLM 生成 → 批判 Agent 审计 → 输出拦截替换）、反谄媚机制（ANTI_SYCOPHANCY_RULES）、策展式记忆系统（小星球）、双模型 LLM 策略——均为独立设计与实现。
2. 项目基于开源技术栈（React、FastAPI、SQLAlchemy、Python、OpenAI 兼容 API）构建，所有核心业务逻辑均为原创代码。
3. 7 个演示案例的场景设计与安全闭环标注为原创内容。
4. 项目参考了《人工智能拟人化互动服务管理暂行办法》（2026.7.15 施行）的合规要求，合规路线图基于公开发布的法规文本。
5. 学习引导模块的苏格拉底式提问方法为公开教育理念，具体 Prompt 策略指令为原创设计。
6. 若由此产生知识产权纠纷，由参赛者自行承担。

第十章 · 隐私与安全设计

9.1 数据最小化原则

数据类型	存储方式	保留期限	说明
对话消息	SQLite（自托管，per-user 隔离）	用于会话恢复与上下文	仅当前账号本人可见；单文件库，部署者自持数据，可整体删除
情景记忆摘要	SQLite（per-user 隔...	30 天滚动过期	只存结构化摘要（话题/情绪/引导线索）， 不含对话原文
星球记忆条目	SQLite（per-user 隔...	孩子可随时删除	仅存孩子主动策展的内容；信任模式（14+）家长端不可见星球概览
共创故事	SQLite（per-user 隔...	默认仅孩子可见	孩子主动分享后家长端才可见（shared_with_parent）
家长告警/摘要	SQLite（per-family 隔离）	长期	脱敏后的统计摘要，不展示对话原文

9.2 家长可见性分级

年龄段	家长可见内容	家长不可见内容
5-7 / 8-10 岁（守护模式）	每轮主题摘要、风险提醒、使用统计、星球概览	对话原文
11-13 岁（过渡模...	周度摘要、高风险事件即时提醒	对话原文、星球内容（默认私密，孩子选择分享的除外）
14 岁及以上（信任模式）	高风险事件提醒（仅在风险等级 ≥2 时）	对话原文、星球概览、日常话题统计

9.3 合规对照

法规要求（《拟人化办法》）	安心童伴状态
禁止诱导不安全行为	✅ 已覆盖：8 步 Pipeline 多层拦截 + 危机模板确定性返回
禁止虚拟亲密关系	✅ 已覆盖：反谄媚 Prompt + 批判审计 + "不替代真人"原则
监护人同意	✅ 已覆盖：注册强制勾选，前后端双校验
未成年人模式	✅ 已覆盖：四年龄档三模式（5-7/8-10 守护、11-13 过渡、14+ 信任）
年龄识别	✅ 已覆盖：注册时选择年龄档（儿童账号必填）
AI 身份标识	✅ 已覆盖：聊天页常驻 AI 身份徽章 + Prompt 声明 + 主页/落地页页脚声明
2 小时使用提醒	✅ 已覆盖：服务端累计当日使用时长，前端弹窗温暖提醒（可关闭，不强制锁）
算法备案	⚠️ 正式上线前完成网信办算法备案（已评估）

合规完成度：7/8 项已覆盖（87.5%），1 项评估中。

附录 A · 演示案例

7 个核心演示案例

#	案例	展示的 Agent 能力	安全闭环
1	 防无边迎合 ："我觉得没人喜欢我，只有 AI 理解我"	意图理解 → 反谄媚策略 → 引导现实连接	不附和 → 不强化依赖 → 鼓励真人连接
2	 隐私保护 ："网友说要给我寄礼物，让我把地址告诉他"	意图理解 → 安全引导 → 家长提醒	隐私检测 → 温和解释 → 中风险家长提醒
3	 校园欺凌 ："同学总是推我，还说不许告诉老师"	意图理解 → 欺凌支持策略 → 家长提醒	确认"不是你的错" → 鼓励找大人 → 中风险家长提醒
4	 高风险情绪（危机） ："我不想活了"	意图理解 → 跳过 LLM → 危机模板	⛔ 不尝试治愈/不深入话题/不附和/不评判 → 引导联系家人或拨打 12355
5	 故事陪伴 ："给我讲一个小恐龙交朋友的故事"	正常陪伴 → 8 步完整 Pipeline	安全生成 → 批判 Agent 审计 → 建议种小星球
6	 学习引导（新） ："帮我做这道数学题"	苏格拉底式提问 → 引导思考 → 不代写	先问"已知条件是什么？" → 引导而非给答案
7	 语音互动（新） ：语音说"为什么天空是蓝色的？"	语音识别（Web Speech） → 年龄适配 → 学习引导	低龄档用比喻解释 / 高龄档引入瑞利散射概念

建议演示顺序

评委体验路径：儿童主页（首站二选一 + 安全承诺条）→ 案例 1（反谄媚，最独特）→ 案例 4（危机模板，最震撼）→ 案例 6（学习引导）→ 案例 7（语音互动）→ 小星球（策展记忆 + 生命树 + 星球罗盘）→ 家长端安全引擎演示台（回放案例 4 决策链）→ 家长守护仪表盘（看闭环）

安心童伴 AI —— 有边界的可信 AI 伙伴，为 5-14 岁儿童少年而生。

本地一键复现：`pip install -r backend/requirements.txt → cd frontend && npm install && npm run build → python scripts/start_server.py`（自动建库 + 演示数据，默认端口 8765）

演示账号：儿童端 `demo_kid`（PIN 1234）/ 家长端 `demo_parent`（PIN 0000）；无 LLM API Key 也可完整体验（规则回退模式，界面有标注）

来源

1. 《人工智能拟人化互动服务管理暂行办法》. 国务院公报 2026年第17号. 2026-04.
https://www.gov.cn/gongbao/2026/issue_12806/202606/content_7072472.html ↩
2. 恒都快评 | AI拟人化互动新规施行: 陪聊智能体集中下线. 恒都律所. 2026-07. <https://hengdulaw.com/Category30-1906> ↩
3. 旷欣然等. 基于苏格拉底式对话的智能数学辅导系统. 现代教育技术. 2026(6). ↩